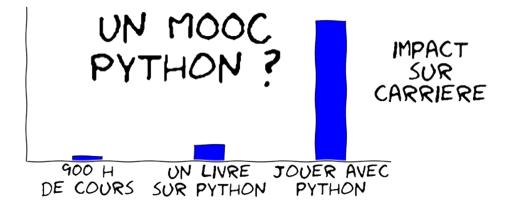


DES FONDAMENTAUX AU CONCEPTS AVANCÉS DU LANGAGE SESSION 2 - 17 SEPTEMBRE 2018

Thierry PARMENTELAT

Arnaud LEGOUT









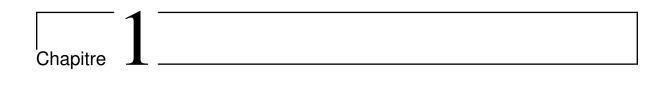
https://www.fun-mooc.fr

Licence CC BY-NC-ND Thierry Parmentelat et Arnaud Legout

Table des matières

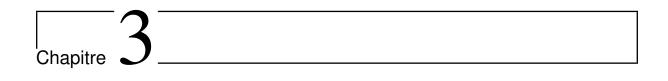
1	Intro	Introduction au MOOC et aux outils Python		
2	Noti	ons de base, premier programme en Python	7	
3	Renforcement des notions de base, références partagées			
	3.1		10	
		3.1.1 Complément - niveau basique	10	
		1	11	
		3.1.3 Complément - niveau avancé	11	
	3.2	Fichiers et utilitaires	15	
		3.2.1 Complément - niveau basique	15	
		3.2.2 Complément - niveau avancé	18	
	3.3	Formats de fichiers: JSON et autres	19	
		3.3.1 Compléments - niveau basique	19	
		3.3.2 Compléments - niveau intermédiaire	20	
	3.4	Fichiers systèmes	22	
		3.4.1 Complément - niveau avancé	22	
	3.5	La construction de tuples	24	
		3.5.1 Complément - niveau intermédiaire	24	
	3.6	Sequence unpacking	28	
		3.6.1 Complément - niveau basique	28	
		3.6.2 Complément - niveau intermédiaire	30	
		3.6.3 Pour en savoir plus	32	
	3.7	Plusieurs variables dans une boucle for	33	
		3.7.1 Complément - niveau basique	33	
		3.7.2 Complément - niveau intermédiaire	33	
	3.8	Fichiers	36	
		3.8.1 Exercice - niveau basique	36	
	3.9	Sequence unpacking	38	
		3.9.1 Exercice - niveau basique	38	
	3.10	Dictionnaires	39	
		3.10.1 Complément - niveau basique	39	
		3.10.2 Complément - niveau intermédiaire	42	
		3.10.3 Complément - niveau avancé	45	
	3.11	Clés immuables	48	
	J.11	3.11.1 Complément - niveau intermédiaire	48	
	3.12	*	50	
	0.12	3.12.1 Complément - niveau intermédiaire	50	
		5.12.1 Complement inventinential		

	3.12.2 Complément - niveau avancé	52
3.13		53
	3.13.1 Exercice - niveau basique	53
3.14	Fusionner des données	54
	3.14.1 Exercices	54
3.15	Ensembles	58
	3.15.1 Complément - niveau basique	58
3.16	Ensembles	63
	3.16.1 Exercice - niveau basique	63
		63
3.17	Exercice sur les ensembles	64
		64
3.18	tryelse finally	66
	3.18.1 Complément - niveau intermédiaire	66
3.19	L'opérateur is	69
		69
	3.19.2 Complément - niveau intermédiaire	70
3.20	Listes infinies & références circulaires	73
	1	73
3.21	Les différentes copies	76
	3.21.1 Complément - niveau basique	76
	3.21.2 Complément - niveau intermédiaire	77
3.22		80
	1	80
3.23	Affectation simultanée	82
	3.23.1 Complément - niveau basique	82
3.24	Les instructions += et autres revisitées	83
	3.24.1 Complément - niveau intermédiaire	83
3.25		86
	3.25.1 Exercice - niveau basique	86



Introduction au MOOC et aux outils Python $^{\mathsf{Chapitre}}2^{\mathsf{Chapitre}}$

Notions de base, premier programme en Python



Renforcement des notions de base, références partagées

3.1 Les fichiers

3.1.1 Complément - niveau basique

Voici quelques utilisations habituelles du type fichier en Python.

Avec un context manager

Nous avons vu dans la vidéo les mécanismes de base sur les fichiers. Nous avons vu notamment qu'il est important de bien fermer un fichier après usage. On a vu aussi qu'il est recommandé de **toujours** utiliser l'instruction with et de contrôler son encodage. Il est donc recommandé de faire :

```
In [1]: # avec un `with' on garantit la fermeture du fichier
      with open("foo.txt", "w", encoding='utf-8') as sortie:
      for i in range(2):
            sortie.write(f"{i}\n")
```

Les modes d'ouverture

101

Les modes d'ouverture les plus utilisés sont :

- 'r' (la chaîne contenant l'unique caractère r) pour ouvrir un fichier en lecture seulement;
- 'w' en écriture seulement; le contenu précédent du fichier, s'il existait, est perdu;
- 'a' en écriture seulement; mais pour ajouter du contenu en fin de fichier.

Voici par exemple comment on pourrait ajouter deux lignes de texte dans le fichier foo.txt qui contient, à ce stade du notebook, deux entiers :

```
In [2]: # on ouvre le fichier en mode 'a' comme append (= ajouter)
    with open("foo.txt", "a", encoding='utf-8') as sortie:
        for i in range(100, 102):
            sortie.write(f"{i}\n")

In [3]: # maintenant on regarde ce que contient le fichier
    with open("foo.txt", encoding='utf-8') as entree: # remarquez que sans 'mode', on our
    for line in entree:
        # line contient déjà un retour à la ligne
        print(line, end='')
0
1
100
```

Il existe de nombreuses variantes au mode d'ouverture, pour par exemple :

- ouvrir le fichier en lecture *et* en écriture (mode +);
- ouvrir le fichier en mode binaire (mode b).

Ces variantes sont décrites dans la section sur la fonction built-in open dans la documentation Python.

3.1. LES FICHIERS

3.1.2 Complément - niveau intermédiaire

Un fichier est un itérateur

Nous reparlerons des notions d'itérable et d'itérateur dans les semaines suivantes. Pour l'instant, on peut dire qu'un fichier - qui donc **est itérable** puisqu'on peut le lire par une boucle for - est aussi **son propre itérateur**. Cela implique que l'on ne peut le parcourir qu'une fois dans une boucle for. Pour le reparcourir, il faut le fermer et l'ouvrir de nouveau.

Par conséquent, écrire deux boucles for imbriquées sur **le même objet fichier** ne **fonctionnerait pas** comme on pourrait s'y attendre.

3.1.3 Complément - niveau avancé

Autres méthodes

Vous pouvez également accéder à des fonctions de beaucoup plus bas niveau, notamment celle fournies directement par le système d'exploitation; nous allons en décrire deux parmi les plus utiles.

```
Digression - repr()
```

Comme nous allons utiliser maintenant des outils d'assez bas niveau pour lire du texte, pour examiner ce texte nous allons utiliser la fonction repr(), et voici pourquoi :

```
abc
def
```

'abc\ndef\n'

Lire un contenu - bas niveau

Revenons aux fichiers; la méthode read() permet de lire dans le fichier un buffer d'une certaine taille :

```
In [10]: # read() retourne TOUT le contenu
         # ne pas utiliser avec de très gros fichiers bien sûr
         # une autre façon de montrer tout le contenu du fichier
         with open("foo.txt", encoding='utf-8') as entree:
             full_contents = entree.read()
             print(f"Contenu complet\n{full_contents}", end="")
Contenu complet
1
100
101
In [11]: # lire dans le fichier deux blocs de quatre caractères
         with open("foo.txt", encoding='utf-8') as entree:
             for bloc in range(2):
                 print(f"Bloc {bloc} >>{repr(entree.read(4))}<<")</pre>
Bloc 0 \gg 0 n1 n' <<
Bloc 1 >> 100n <<
```

On voit donc que chaque bloc contient bien quatre caractères en comptant les sauts de ligne :

bloc#	contenu
0	un 0, un <i>newline</i> , un 1, un <i>newline</i>
1	un 1, deux 0, un newline

La méthode flush

Les entrées-sorties sur fichier sont bien souvent *bufferisées* par le système d'exploitation. Cela signifie qu'un appel à write ne provoque pas forcément une écriture immédiate, car pour des

3.1. LES FICHIERS

raisons de performance on attend d'avoir suffisamment de matière avant d'écrire sur le disque.

Il y a des cas où ce comportement peut s'avérer gênant, et où on a besoin d'écrire immédiatement (et donc de vider le *buffer*), et c'est le propos de la méthode flush.

Fichiers textuels et fichiers binaires

De la même façon que le langage propose les deux types str et bytes, il est possible d'ouvrir un fichier en mode *textuel* ou en mode *binaire*.

Les fichiers que nous avons vus jusqu'ici étaient ouverts en mode *textuel* (c'est le défaut), et c'est pourquoi nous avons interagi avec eux avec des objets de type str :

Lorsque ce n'est pas le comportement souhaité, on peut :

- ouvrir le fichier en mode binaire pour cela on ajoute le caractère b au mode d'ouverture;
- et on peut alors interagir avec le fichier avec des objets de type bytes

Pour illustrer ce trait, nous allons : 0. créer un fichier en mode texte, et y insérer du texte en UTF-8; 0. relire le fichier en mode binaire, et retrouver le codage des différents caractères.

```
In [13]: # phase 1 : on écrit un fichier avec du texte en UTF-8
         # on ouvre donc le fichier en mode texte
         # en toute rigueur il faut préciser l'encodage,
         # si on ne le fait pas il sera déterminé
         # à partir de vos réglages système
         with open('strbytes', 'w', encoding='utf-8') as output:
             output.write("déjà l'été\n")
In [14]: # phase 2: on ouvre le fichier en mode binaire
         with open('strbytes', 'rb') as rawinput:
             # on lit tout le contenu
             octets = rawinput.read()
             # qui est de type bytes
             print("on a lu un objet de type", type(octets))
              # si on regarde chaque octet un par un
             for i, octet in enumerate(octets):
                  print(f"{i} \rightarrow {repr(chr(octet))} [{hex(octet)}]")
on a lu un objet de type <class 'bytes'>
0 \rightarrow 'd' [0x64]
1 \rightarrow '\tilde{A}' [0xc3]
```

```
2 \rightarrow ' \bigcirc ' [0xa9]
3 \rightarrow 'j' [0x6a]
4 \rightarrow '\tilde{A}' [0xc3]
5 \rightarrow ' xa0' [0xa0]
6 \rightarrow ' ' [0x20]
7 \rightarrow 'l' [0x6c]
8 \rightarrow "'" [0x27]
9 \rightarrow '\tilde{A}' [0xc3]
10 \rightarrow ' \bigcirc ' [0xa9]
11 \rightarrow 't' [0x74]
12 \rightarrow '\tilde{A}' [0xc3]
13 \rightarrow ' \bigcirc ' [0xa9]
14 \rightarrow ' r' [0xd]
15 \rightarrow ' n' [0xa]
```

Vous retrouvez ainsi le fait que l'unique caractère Unicode é a été encodé par UTF-8 sous la forme de deux octets de code hexadécimal 0xc3 et 0xa9.

Vous pouvez également consulter ce site qui visualise l'encodage UTF-8, avec notre séquence d'entrée :

https://mothereff.in/utf-8#d%C3%A9j%C3%A0%20l%27%C3%A9t%C3%A9%0A

Ce qui correspond au fait que nos quatre caractères non-ASCII (3 x é et 1 x à) sont tous encodés par UTF-8 comme deux octets, comme vous pouvez vous en assurer ici pour é et là pour à.

Pour en savoir plus

Pour une description exhaustive vous pouvez vous reporter :

- au glossaire sur la notion de object file,
- et aussi et surtout au module 10 qui décrit plus en détail les fonctionnalités disponibles.

3.2 Fichiers et utilitaires

3.2.1 Complément - niveau basique

Outre les objets fichiers créés avec la fonction open, comme on l'a vu dans la vidéo, et qui servent à lire et écrire à un endroit précis, une application a besoin d'un minimum d'utilitaires pour **parcourir l'arborescence de répertoires et fichiers**, c'est notre propos dans ce complément.

Le module os.path (obsolète)

Avant la version python-3.4, la librairie standard offrait une conjonction d'outils pour ce type de fonctionnalités :

- le module os .path, pour faire des calculs sur les les chemins et noms de fichiers doc,
- le module os pour certaines fonctions complémentaires comme renommer ou détruire un fichier doc,
- et enfin le module glob pour la recherche de fichiers, par exemple pour trouver tous les fichiers en *.txt doc.

Cet ensemble un peu disparate a été remplacé par une **librairie unique** pathlib, qui fournit toutes ces fonctionnalités sous un interface unique et moderne, que nous **recommandons** évidemment d'utiliser pour **du nouveau code**.

Avant d'aborder pathlib, voici un très bref aperçu de ces trois anciens modules, pour le cas - assez probable - où vous les rencontreriez dans du code existant; tous les noms qui suivent correspondent à des **fonctions** - par opposition à pathlib qui, comme nous allons le voir, offre une interface orientée objet :

- os.path.join ajoute '/' ou " entre deux morceaux de chemin, selon l'OS
- os.path.basename trouve le nom de fichier dans un chemin
- os.path.dirname trouve le nom du directory dans un chemin
- os.path.abspath calcule un chemin absolu, c'est-à-dire à partir de la racine du filesystem
- os.path.exists pour savoir si un chemin existe ou pas (fichier ou répertoire)
- os.path.isfile (et isdir) pour savoir si un chemin est un fichier (et un répertoire)
- os.path.getsize pour obtenir la taille du fichier
- os.path.getatime et aussi getmtime et getctime pour obtenir les dates de création/modification d'un fichier
- os.remove (ou son ancien nom os.unlink), qui permet de supprimer un fichier
- os.rmdir pour supprimer un répertoire (mais qui doit être vide)
- os.removedirs pour supprimer tout un répertoire avec son contenu, récursivement si nécessaire
- os.rename pour renommer un fichier
- glob.glob comme dans par exemple glob.glob("*.txt")

Le module pathlib

C'est la méthode recommandée aujourd'hui pour travailler sur les fichiers et répertoires.

Orienté Objet

Comme on l'a mentionné pathlib offre une interface orientée objet; mais qu'est-ce

que ça veut dire au juste?

Ceci nous donne un prétexte pour une première application pratique des notions de module (que nous avons introduits en fin de semaine 2) et de classe (que nous allons voir en fin de semaine).

De même que le langage nous propose les types *builtin* int et str, le module pathlib nous expose **un type** (on dira plutôt **une classe**) qui s'appelle Path, que nous allons importer comme ceci :

```
In [1]: from pathlib import Path
```

Nous allons faire tourner un petit scénario qui va créer un fichier :

```
In [2]: # le nom de notre fichier jouet
    nom = 'fichier-temoin'
```

Pour commencer, nous allons vérifier si le fichier en question existe.

Pour ça nous créons un objet qui est une instance de la classe Path, comme ceci :

```
In [3]: # on crée un objet de la classe Path, associé au nom de fichier
    path = Path(nom)
```

Vous remarquez que c'est consistent avec par exemple :

```
In [4]: # transformer un float en int
    i = int(3.5)
```

en ce sens que le type (int ou Path) se comporte comme une usine pour créer des objets du type en question.

Quoi qu'il en soit, cet objet path offre un certain nombre de méthodes; pour les voir puisque nous sommes dans un notebook, je vous invite dans la cellule suivante à utiliser l'aide en ligne en appuyant sur la touche 'Tabulation' après avoir ajouté un . comme si vous alliez envoyer une méthode à cet objet

```
path.[taper la touche TAB]
```

et le notebook vous montrera la liste des méthodes disponibles.

Métadonnées

Voici quelques exemples qui montrent comment accéder aux métadonnées de ce fichier :

Pour ceux que ça intéresse, l'objet retourné par cette méthode stat est un namedtuple, que l'on va voir très bientôt.

On accède aux différentes informations comme ceci:

```
In [10]: # la taille du fichier en octets est de 11
         # car il faut compter un caractère "newline" en fin de ligne
         path.stat().st_size
Out[10]: 12
In [11]: # la date de dernière modification, sous forme d'un entier
         # c'est le nombre de secondes depuis le 1er Janvier 1970
         mtime = path.stat().st_mtime
         mtime
Out[11]: 1537703765.728249
In [12]: # que je peux rendre lisible comme ceci
         # en anticipant sur le module datetime
         from datetime import datetime
         mtime_datetime = datetime.fromtimestamp(mtime)
         mtime_datetime
Out[12]: datetime.datetime(2018, 9, 23, 13, 56, 5, 728249)
In [13]: # ou encore, si je formatte pour n'obtenir que
         # l'heure et la minute
         f"{mtime_datetime:%H:%M}"
Out[13]: '13:56'
   Détruire un fichier
In [14]: # je peux maintenant détruire le fichier
         path.unlink()
In [15]: # ou encore mieux, si je veux détruire
         # seulement dans le cas où il existe je peux aussi faire
         try:
             path.unlink()
         except FileNotFoundError:
             print("no need to remove")
no need to remove
```

Recherche de fichiers

Maintenant je voudrais connaître la liste des fichiers de nom *.json dans le directory data.

La méthode la plus naturelle consiste à créer une instance de Path associée au directory lui-même :

```
In [18]: dirpath = Path('./data/')
```

Sur cet objet la méthode glob nous retourne un itérable qui contient ce qu'on veut :

Documentation complète

Voyez la documentation complète ici

3.2.2 Complément - niveau avancé

Pour ceux qui sont déjà familiers avec les classes, j'en profite pour vous faire remarquer le type de notre objet path

```
In [20]: type(path)
Out[20]: pathlib.WindowsPath
```

qui n'est pas Path, mais en fait une sous-classe de Path qui est - sur la plateforme du MOOC au moins, qui fonctionne sous linux - un objet de type PosixPath, qui est une sous-classe de Path, comme vous pouvez le voir :

Ce qui fait que mécaniquement, path est bien une instance de Path

```
In [22]: isinstance(path, Path)
Out[22]: True
```

ce qui est heureux puisqu'on avait utilisé Path() pour construire l'objet path au départ :)

3.3 Formats de fichiers : JSON et autres

3.3.1 Compléments - niveau basique

Voici quelques mots sur des outils Python fournis dans la bibliothèque standard, et qui permettent de lire ou écrire des données dans des fichiers.

Le problème

Les données dans un programme Python sont stockées en mémoire (la RAM), sous une forme propice aux calculs. Par exemple un petit entier est fréquemment stocké en binaire dans un mot de 64 bits, qui est prêt à être soumis au processeur pour faire une opération arithmétique.

Ce format ne se prête pas forcément toujours à être transposé tel quel lorsqu'on doit écrire des données sur un support plus pérenne, comme un disque dur, ou encore sur un réseau pour transmission distante - ces deux supports étant à ce point de vue très voisins.

Ainsi par exemple il pourra être plus commode d'écrire notre entier sur disque, ou de le transmettre à un programme distant, sous une forme décimale qui sera plus lisible, sachant que par ailleurs toutes les machines ne codent pas un entier de la même façon.

Il convient donc de faire de la traduction dans les deux sens entre représentations d'une part en mémoire, et d'autre part sur disque ou sur réseau (à nouveau, on utilise en général les mêmes formats pour ces deux usages).

Le format JSON

Le format sans aucun doute le plus populaire à l'heure actuelle est le format JSON pour *JavaScript Object Notation*.

Sans trop nous attarder nous dirons que JSON est un encodage - en anglais marshalling - qui se prête bien à la plupart des types de base que l'on trouve dans les langages modernes comme Python, Ruby ou JavaScript.

La bibliothèque standard de Python contient le module json que nous illustrons très rapidement ici :

```
In [1]: import json

# En partant d'une donnée construite à partir de types de base
data = [
          # des types qui ne posent pas de problème
          [1, 2, 'a', [3.23, 4.32], {'eric': 32, 'jean': 43}],
          # un tuple
          (1, 2, 3),
]

# sauver ceci dans un fichier
with open("s1.json","w", encoding='utf-8') as json_output:
          json.dump(data, json_output)
```

```
# et relire le résultat
with open("s1.json", encoding='utf-8') as json_input:
    data2 = json.load(json_input)
```

Limitations de json

Certains types de base ne sont pas supportés par le format JSON (car ils ne sont pas natifs en JavaScript), c'est le cas notamment pour :

- tuple, qui se fait encoder comme une liste;
- complex, set et frozenset, que l'on ne peut pas encoder du tout (sans étendre la bibliothèque).

C'est ce qui explique ce qui suit :

Malgré ces petites limitations, ce format est de plus en plus populaire, notamment parce qu'on peut l'utiliser pour communiquer avec des applications Web écrites en JavaScript, et aussi parce qu'il est très léger, et supporté par de nombreux langages.

3.3.2 Compléments - niveau intermédiaire

Le format csv

Le format csv pour *Comma Separated Values*, originaire du monde des tableurs, peut rendre service à l'occasion, il est proposé dans le module csv.

Le format pickle

Le format pickle remplit une fonctionnalité très voisine de JSON, mais est spécifique à Python. C'est pourquoi, malgré des limites un peu moins sévères, son usage tend à rester plutôt marginal pour l'échange de données, on lui préfère en général le format JSON.

Par contre, pour la sauvegarde locale d'objets Python (pour, par exemple, faire des points de reprises d'un programme), il est très utile. Il est implémenté dans le module pickle.

Le format XML

Vous avez aussi très probablement entendu parler de XML, qui est un format assez populaire également.

Cela dit, la puissance, et donc le coût, de XML et JSON ne sont pas du tout comparables, XML étant beaucoup plus flexible mais au prix d'une complexité de mise en œuvre très supérieure.

Il existe plusieurs souches différentes de bibliothèques prenant en charge le format XML, qui sont introduites ici.

Pour en savoir plus

Voyez la page sur les formats de fichiers dans la documentation Python.

3.4 Fichiers systèmes

3.4.1 Complément - niveau avancé

Dans ce complément, nous allons voir comment un programme Python interagit avec ce qu'il est convenu d'appeler le système d'entrées-sorties standard du système d'exploitation.

Introduction

Dans un ordinateur, le système d'exploitation (Windows, Linux, macOS, etc.) comprend un noyau (*kernel*) qui est un logiciel qui a l'exclusivité pour interagir physiquement avec le matériel (processeur(s), mémoire, disque(s), périphériques, etc.); il offre aux programmes utilisateur (*userspace*) des abstractions pour interagir avec ce matériel.

La notion de fichier, telle qu'on l'a vue dans la vidéo, correspond à une de ces abstractions; elle repose principalement sur les quatre opérations élémentaires suivantes :

- open;
 close;
- read;
- write.

Parmi les autres conventions d'interaction entre le système (pour être précis : le *shell*) et une application, il y a les notions de :

- entrée standard (*standard input*, en abrégé stdin);
- sortie standard (standard output, en abrégé stdout);
- erreur standard (standard error, en abrégé stderr).

Ceci est principalement pertinent dans le contexte d'un terminal. L'idée c'est que l'on a envie de pouvoir *rediriger* les entrées-sorties d'un programme sans avoir à le modifier. De la sorte, on peut également *chaîner* des traitements à l'aide de *pipes*, sans avoir besoin de sauver les résultats intermédiaires sur disque.

Ainsi par exemple lorsque l'on écrit :

```
$ monprogramme < fichier_entree > fichier_sortie
```

Les deux fichiers en question sont ouverts par le *shell*, et passés à monprogramme - que celuici soit écrit en C, en Python ou en Java - sous la forme des fichiers stdin et stdout respectivement, et donc **déjà ouverts**.

Le module sys

L'interpréteur Python vous expose ces trois fichiers sous la forme d'attributs du module sys :

Dans le contexte du notebook vous pouvez constater que les deux flux de sortie sont implémentés comme des classes spécifiques à IPython. Si vous exécutez ce code localement dans votre ordinateur vous allez sans doute obtenir quelque chose comme :

```
<_io.TextIOWrapper name='<stdin>' mode='r' encoding='UTF-8'>
<_io.TextIOWrapper name='<stdout>' mode='w' encoding='UTF-8'>
<_io.TextIOWrapper name='<stderr>' mode='w' encoding='UTF-8'>
```

On n'a pas extrêmement souvent besoin d'utiliser ces variables en règle générale, mais elles peuvent s'avérer utiles dans des contextes spécifiques.

Par exemple, l'instruction print écrit dans sys.stdout (c'est-à-dire la sortie standard). Et comme sys.stdout est une variable (plus exactement stdout est un attribut dans le module référencé par la variable sys) et qu'elle référence un objet fichier, on peut lui faire référencer un autre objet fichier et ainsi rediriger depuis notre programme tous les sorties, qui sinon iraient sur le terminal, vers un fichier de notre choix :

```
In [2]: # ici je fais exprès de ne pas utiliser un `with`
        # car très souvent les deux redirections apparaissent
        # dans des fonctions différentes
        import sys
        # on ouvre le fichier destination
        autre_stdout = open('ma_sortie.txt', 'w', encoding='utf-8')
        # on garde un lien vers le fichier sortie standard
        # pour le réinstaller plus tard si besoin.
        tmp = sys.stdout
        print('sur le terminal')
        # première redirection
        sys.stdout = autre_stdout
        print('dans le fichier')
        # on remet comme c'était au début
        sys.stdout = tmp
        # et alors pour être propre on n'oublie pas de fermer
        autre_stdout.close()
        print('de nouveau sur le terminal')
sur le terminal
de nouveau sur le terminal
In [3]: # et en effet, dans le fichier on a bien
        with open("ma_sortie.txt", encoding='utf-8') as check:
            print(check.read())
dans le fichier
```

3.5 La construction de tuples

3.5.1 Complément - niveau intermédiaire

Les tuples et la virgule terminale

Comme on l'a vu dans la vidéo, on peut construire un tuple à deux éléments - un couple - de quatre façons :

Comme on le voit:

- en réalité la parenthèse est parfois superflue; mais il se trouve qu'elle est largement utilisée pour améliorer la lisibilité des programmes, sauf dans le cas du tuple unpacking; nous verrons aussi plus bas qu'elle est parfois nécessaire selon l'endroit où le tuple apparaît dans le programme;
- la **dernière virgule est optionnelle** aussi, c'est le cas pour les tuples à au moins 2 éléments nous verrons plus bas le cas des tuples à un seul élément.

Conseil pour la présentation sur plusieurs lignes

En général d'ailleurs, la forme avec parenthèses et virgule terminale est plus pratique. Considérez par exemple l'initialisation suivante; on veut créer un tuple qui contient des listes (naturellement un tuple peut contenir n'importe quel objet Python), et comme c'est assez long on préfère mettre un élément du tuple par ligne :

L'avantage lorsqu'on choisit cette forme (avec parenthèses, et avec virgule terminale), c'est d'abord qu'il n'est pas nécessaire de mettre un backslash à la fin de chaque ligne; parce que l'on est à l'intérieur d'une zone parenthésée, l'interpréteur Python "sait" que l'instruction n'est pas terminée et va se continuer sur la ligne suivante.

Deuxièmement, si on doit ultérieurement ajouter ou enlever un élément dans le tuple, il suffira d'enlever ou d'ajouter toute une ligne, sans avoir à s'occuper des virgules; si on avait choisi de ne pas faire figurer la virgule terminale, alors pour ajouter un élément dans le tuple après le dernier, il ne faut pas oublier d'ajouter une virgule à la ligne précédente. Cette simplicité se répercute au niveau du gestionnaire de code source, où les différences dans le

code sont plus faciles à visualiser.

Signalons enfin que ceci n'est pas propre aux tuples. La virgule terminale est également optionnelle pour les listes, ainsi d'ailleurs que pour tous les types Python où cela fait du sens, comme les dictionnaires et les ensembles que nous verrons bientôt. Et dans tous les cas où on opte pour une présentation multi-lignes, il est conseillé de faire figurer une virgule terminale.

Tuples à un élément

Pour revenir à présent sur le cas des tuples à un seul élément, c'est un cas particulier, parmi les quatre syntaxes que l'on a vues ci-dessus, on obtiendrait dans ce cas :

```
In [4]: # ATTENTION : ces deux premières formes ne construisent pas un tuple !
    simple1 = 1
    simple2 = (1)
    # celles-ci par contre construisent bien un tuple
    simple3 = 1,
    simple4 = (1,)
```

- Il est bien évident que la première forme ne crée pas de tuple;
- et en fait la seconde non plus, car Python lit ceci comme une expression parenthésée, avec seulement un entier.

Et en fait ces deux premières formes créent un entier simple :

```
In [5]: type(simple2)
Out[5]: int
```

Les deux autres formes créent par contre toutes les deux un tuple à un élément comme on cherchait à le faire :

```
In [6]: type(simple3)
Out[6]: tuple
In [7]: simple3 == simple4
Out[7]: True
```

Pour conclure, disons donc qu'il est conseillé de **toujours mentionner une virgule termi- nale** lorsqu'on construit des tuples.

Parenthèse parfois obligatoire

Dans certains cas vous vous apercevrez que la parenthèse est obligatoire. Par exemple on peut écrire :

Mais si on essaie d'écrire le même test sans les parenthèses :

Python lève une erreur de syntaxe; encore une bonne raison pour utiliser les parenthèses.

Addition de tuples

Bien que le type tuple soit immuable, il est tout à fait légal d'additionner deux tuples, et l'addition va produire un **nouveau** tuple :

Ainsi on peut également utiliser l'opérateur += avec un tuple qui va créer, comme précédemment, un nouvel objet tuple :

Construire des tuples élaborés

Malgré la possibilité de procéder par additions successives, la construction d'un tuple peut s'avérer fastidieuse.

Une astuce utile consiste à penser aux fonctions de conversion, pour construire un tuple à partir de - par exemple - une liste. Ainsi on peut faire par exemple ceci :

Digression sur les noms de fonctions prédéfinies

Remarque : Vous avez peut-être observé que nous avons choisi de ne pas appeler notre tuple simplement tuple. C'est une bonne pratique en général d'éviter les noms de fonctions prédéfinies par Python.

Ces variables en effet sont des variables "comme les autres". Imaginez qu'on ait en fait deux tuples à construire comme ci-dessus, voici ce qu'on obtiendrait si on n'avait pas pris cette précaution :

```
In [14]: liste = range(10)
         # ATTENTION : ceci redéfinit le symbole tuple
         tuple = tuple(liste)
         tuple
Out[14]: (0, 1, 2, 3, 4, 5, 6, 7, 8, 9)
In [15]: # si bien que maintenant on ne peut plus faire ceci
         # car à ce point, tuple ne désigne plus le type tuple
         # mais l'objet qu'on vient de créer
         autre_liste = range(100)
         autre_tuple = tuple(autre_liste)
        TypeError
                                                  Traceback (most recent call last)
        <ipython-input-15-15ef2d1e6804> in <module>()
          3 # mais l'objet qu'on vient de créer
          4 autre_liste = range(100)
    ---> 5 autre_tuple = tuple(autre_liste)
        TypeError: 'tuple' object is not callable
```

Il y a une erreur parce que nous avons remplacé (ligne 2) la valeur de la variable tuple, qui au départ référençait le **type** tuple (ou si on préfère la fonction de conversion), par un **objet** tuple. Ainsi en ligne 5, lorsqu'on appelle à nouveau tuple, on essaie d'exécuter un objet qui n'est pas 'appelable' (not callable en anglais).

D'un autre côté, l'erreur est relativement facile à trouver dans ce cas. En cherchant toutes les occurrences de tuple dans notre propre code on voit assez vite le problème. De plus, je vous rappelle que votre éditeur de texte **doit** faire de la coloration syntaxique, et que toutes les fonctions built-in (dont tuple et list font partie) sont colorées spécifiquement (par exemple, en violet sous IDLE). En pratique, avec un bon éditeur de texte et un peu d'expérience, cette erreur est très rare.

3.6 Sequence unpacking

3.6.1 Complément - niveau basique

Remarque préliminaire : nous avons vainement cherché une traduction raisonnable pour ce trait du langage, connue en anglais sous le nom de *sequence unpacking* ou encore parfois *tuple unpacking*, aussi pour éviter de créer de la confusion nous avons finalement décidé de conserver le terme anglais à l'identique.

Déjà rencontré

L'affectation dans Python peut concerner plusieurs variables à la fois. En fait nous en avons déjà vu un exemple en Semaine 1, avec la fonction fibonacci dans laquelle il y avait ce fragment :

```
for i in range(2, n + 1):
f2, f1 = f1, f1 + f2
```

Nous allons dans ce complément décortiquer les mécanismes derrière cette phrase qui a probablement excité votre curiosité. :)

Un exemple simple

Commençons par un exemple simple à base de tuple. Imaginons que l'on dispose d'un tuple couple dont on sait qu'il a deux éléments :

```
In [1]: couple = (100, 'spam')
```

On souhaite à présent extraire les deux valeurs, et les affecter à deux variables distinctes. Une solution naïve consiste bien sûr à faire simplement :

Cela fonctionne naturellement très bien, mais n'est pas très pythonique - comme on dit;) Vous devez toujours garder en tête qu'il est rare en Python de manipuler des indices. Dès que vous voyez des indices dans votre code, vous devez vous demander si votre code est pythonique.

On préfèrera la formulation équivalente suivante :

La logique ici consiste à dire : affecter les deux variables de sorte que le tuple (gauche, droite) soit égal à couple. On voit ici la supériorité de cette notion d'unpacking sur la manipulation d'indices : vous avez maintenant des variables qui expriment la nature de l'objet manipulé, votre code devient expressif, c'est-à-dire auto-documenté.

Remarquons que les parenthèses ici sont optionnelles - comme lorsque l'on construit un tuple - et on peut tout aussi bien écrire, et c'est le cas d'usage le plus fréquent d'omission des parenthèses pour le tuple :

Autres types

Cette technique fonctionne aussi bien avec d'autres types. Par exemple, on peut utiliser :

- une syntaxe de liste à gauche du =;
- une liste comme expression à droite du =.

Et on n'est même pas obligés d'avoir le même type à gauche et à droite du signe =, comme ici :

```
In [6]: # membre droit: une liste
    liste = [1, 2, 3]
    # membre gauche : un tuple
    gauche, milieu, droit = liste
    print('gauche', gauche, 'milieu', milieu, 'droit', droit)
gauche 1 milieu 2 droit 3
```

En réalité, les seules contraintes fixées par Python sont que :

- le terme à droite du signe = soit un *itérable* (tuple, liste, string, etc.);
- le terme à gauche soit écrit comme un tuple ou une liste notons tout de même que l'utilisation d'une liste à gauche est rare et peu pythonique;
- les deux termes aient la même longueur en tout cas avec les concepts que l'on a vus jusqu'ici, mais voir aussi plus bas l'utilisation de *arg avec le *extended unpacking*.

La plupart du temps le terme de gauche est écrit comme un tuple. C'est pour cette raison que les deux termes *tuple unpacking* et *sequence unpacking* sont en vigueur.

La façon pythonique d'échanger deux variables

Une caractéristique intéressante de l'affectation par *sequence unpacking* est qu'elle est sûre; on n'a pas à se préoccuper d'un éventuel ordre d'évaluation, les valeurs **à droite** de l'affectation sont **toutes** évaluées en premier, et ainsi on peut par exemple échanger deux variables comme ceci :

```
In [7]: a = 1
    b = 2
    a, b = b, a
    print('a', a, 'b', b)
a 2 b 1
```

Extended unpacking

Le extended unpacking a été introduit en Python 3; commençons par en voir un exemple :

Comme vous le voyez, le mécanisme ici est une extension de *sequence unpacking*; Python vous autorise à mentionner **une seule fois**, parmi les variables qui apparaissent à gauche de l'affectation, une variable **précédée de** *, ici *b.

Cette variable est interprétée comme une **liste de longueur quelconque** des éléments de reference. On aurait donc aussi bien pu écrire :

Ce trait peut s'avérer pratique, lorsque par exemple on s'intéresse seulement aux premiers éléments d'une structure :

3.6.2 Complément - niveau intermédiaire

On a vu les principaux cas d'utilisation de la *sequence unpacking*, voyons à présent quelques subtilités.

Plusieurs occurrences d'une même variable

On peut utiliser **plusieurs fois** la même variable dans la partie gauche de l'affectation :

Attention toutefois, comme on le voit ici, Python **n'impose pas** que les différentes occurrences de a correspondent à **des valeurs identiques** (en langage savant, on dirait que cela ne permet pas de faire de l'unification). De manière beaucoup plus pragmatique, l'interpréteur se contente de faire comme s'il faisait l'affectation plusieurs fois de gauche à droite, c'est-à-dire comme s'il faisait :

```
In []: a = 1; a = 2; a = 3
```

Cette technique n'est utilisée en pratique que pour les parties de la structure dont on n'a que faire dans le contexte. Dans ces cas-là, il arrive qu'on utilise le nom de variable _, dont on rappelle qu'il est légal, ou tout autre nom comme ignored pour manifester le fait que cette partie de la structure ne sera pas utilisée, par exemple :

```
In [12]: entree = [1, 2, 3]
    _, milieu, _ = entree
    print('milieu', milieu)
    ignored, ignored, right = entree
    print('right', right)

milieu 2
right 3
```

En profondeur

Le sequence unpacking ne se limite pas au premier niveau dans les structures, on peut extraire des données plus profondément imbriquées dans la structure de départ; par exemple avec en entrée la liste :

```
In [13]: structure = ['abc', [(1, 2), ([3], 4)], 5]
```

Si on souhaite extraire la valeur qui se trouve à l'emplacement du 3, on peut écrire :

trois 3

Ou encore, sans doute un peu plus lisible :

Naturellement on aurait aussi bien pu écrire ici quelque chose comme :

Affaire de goût évidemment. Mais n'oublions pas une des phrases du Zen de Python *Flat is better than nested*, ce qui veut dire que ce n'est pas parce que vous pouvez faire des structures imbriquées complexes que vous devez le faire. Bien souvent, cela rend la lecture et la maintenance du code complexe, j'espère que l'exemple précédent vous en a convaincu.

Extended unpacking et profondeur

On peut naturellement ajouter de l'extended unpacking à n'importe quel étage d'un unpacking imbriqué :

Dans ce cas, la limitation d'avoir une seule variable de la forme *extended s'applique toujours, naturellement, mais à chaque niveau dans l'imbrication, comme on le voit sur cet exemple.

3.6.3 Pour en savoir plus

— Le PEP (en anglais) qui introduit le extended unpacking.

3.7 Plusieurs variables dans une boucle for

3.7.1 Complément - niveau basique

Nous avons vu précédemment (séquence 'Les tuples', complément 'Sequence unpacking') la possibilité d'affecter plusieurs variables à partir d'un seul objet, comme ceci :

D'une façon analogue, il est possible de faire une boucle for qui itère sur **une seule** liste mais qui *agit* sur **plusieurs variables**, comme ceci :

À chaque itération, on trouve dans entree un tuple (d'abord (1, 2), puis à l'itération suivante (3, 4), etc.); à ce stade les variables a et b vont être affectées à, respectivement, le premier et le deuxième élément du tuple, exactement comme dans le sequence unpacking. Cette mécanique est massivement utilisée en Python.

3.7.2 Complément - niveau intermédiaire

La fonction zip

Voici un exemple très simple qui utilise la technique que l'on vient de voir.

Imaginons qu'on dispose de deux listes de longueurs égales, dont on sait que les entrées correspondent une à une, comme par exemple :

Afin d'écrire facilement un code qui "associe" les deux listes entre elles, Python fournit une fonction *built-in* baptisée zip; voyons ce qu'elle peut nous apporter sur cet exemple :

```
In [4]: list(zip(villes, populations))
Out[4]: [('Paris', 2000000), ('Nice', 400000), ('Lyon', 1000000)]
```

On le voit, on obtient en retour une liste composée de tuples. On peut à présent écrire une boucle for comme ceci :

```
2000000 habitants à Paris
400000 habitants à Nice
1000000 habitants à Lyon
```

Qui est, nous semble-t-il, beaucoup plus lisible que ce que l'on serait amené à écrire avec des langages plus traditionnels.

Tout ceci se généralise naturellement à plus de deux variables :

Remarque : lorsqu'on passe à zip des listes de tailles différentes, le résultat est tronqué, c'est l'entrée **de plus petite taille** qui détermine la fin du parcours.

La fonction enumerate

Une autre fonction très utile permet d'itérer sur une liste avec l'indice dans la liste, il s'agit de enumerate :

Cette forme est **plus simple** et **plus lisible** que les formes suivantes qui sont équivalentes, mais qui ne sont pas pythoniques :

1 Nice 2 Lyon

3.8 Fichiers

3.8.1 Exercice - niveau basique

Calcul du nombre de lignes, de mots et de caractères

On se propose d'écrire une *moulinette* qui annote un fichier avec des nombres de lignes, de mots et de caractères.

Le but de l'exercice est d'écrire une fonction comptage :

- qui prenne en argument un nom de fichier d'entrée (on suppose qu'il existe) et un nom de fichier de sortie (on suppose qu'on a le droit de l'écrire);
- le fichier d'entrée est supposé encodé en UTF-8;
- le fichier d'entrée est laissé intact;
- pour chaque ligne en entrée, le fichier de sortie comporte une ligne qui donne le numéro de ligne, le nombre de mots (séparés par des espaces), le nombre de caractères (y compris la fin de ligne), et la ligne d'origine.

N'oubliez pas de vérifier que vous ajoutez bien les **fins de ligne**, car la vérification automatique est pointilleuse (elle utilise l'opérateur ==), et rejettera votre code si vous ne produisez pas une sortie rigoureusement similaire à ce qui est attendu.

La méthode debug applique votre fonction au premier fichier d'entrée, et affiche le résultat comme dans l'exemple ci-dessus :

Accès aux fichiers d'exemples

Vous pouvez télécharger les fichiers d'exemples :

- Romeo and Juliet
- Lorem Ipsum
- "Une charogne" en UTF-8

3.8. FICHIERS 37

Pour les courageux, je vous donne également "Une charogne" en ISO-8859-15, qui contient le même texte que "Une charogne", mais encodé en Latin-9, connu aussi sous le nom ISO-8859-15.

Ce dernier fichier n'est pas à prendre en compte dans la version basique de l'exercice, mais vous pourrez vous rendre compte par vous-mêmes, au cas où cela ne serait pas clair encore pour vous, qu'il n'est pas facile d'écrire une fonction comptage qui devine l'encodage, c'est-à-dire qui fonctionne correctement avec des entrées indifféremment en Unicode ou Latin, sans que cet encodage soit passé en paramètre à comptage.

C'est d'ailleurs le propos de la bibliothèque chardet qui s'efforce de déterminer l'encodage de fichiers d'entrée, sur la base de modèles statistiques.

3.9 Sequence unpacking

3.9.1 Exercice - niveau basique

Cet exercice consiste à écrire une fonction surgery, qui prend en argument une liste, et qui retourne la **même** liste **modifiée** comme suit :

- si la liste est de taille 0 ou 1, elle n'est pas modifiée;
- si la liste est de taille paire, on intervertit les deux premiers éléments de la liste;
- si elle est de taille impaire, on intervertit les deux derniers éléments.

3.10. DICTIONNAIRES 39

3.10 Dictionnaires

3.10.1 Complément - niveau basique

Ce document résume les opérations courantes disponibles sur le type dict. On rappelle que le type dict est un type **mutable**.

Création en extension

On l'a vu, la méthode la plus directe pour créer un dictionnaire est en extension comme ceci :

Création - la fonction dict

Comme pour les fonctions int ou list, la fonction dict est une fonction de construction de dictionnaire - on dit un constructeur. On a vu aussi dans la vidéo qu'on peut utiliser ce constructeur à base d'une liste de tuples (clé, valeur)

Remarquons qu'on peut aussi utiliser cette autre forme d'appel à dict pour un résultat équivalent :

Remarquez ci-dessus l'absence de quotes autour des clés comme marc. Il s'agit d'un cas particulier de passage d'arguments que nous expliciterons plus longuement en fin de semaine 4.

Accès atomique

Pour accéder à la valeur associée à une clé, on utilise la notation à base de crochets [] :

```
In [4]: print('la valeur pour marc est', annuaire['marc'])
la valeur pour marc est 35
```

Cette forme d'accès ne fonctionne que si la clé est effectivement présente dans le dictionnaire. Dans le cas contraire, une exception KeyError est levée. Aussi si vous n'êtes pas sûr que la clé soit présente, vous pouvez utiliser la méthode get qui accepte une valeur par défaut :

Le dictionnaire est un type mutable, et donc on peut modifier la valeur associée à une clé :

Ou encore, exactement de la même façon, ajouter une entrée :

Enfin pour détruire une entrée, on peut utiliser l'instruction del comme ceci :

Pour savoir si une clé est présente ou non, il est conseillé d'utiliser l'opérateur d'appartenance in comme ceci :

False

Parcourir toutes les entrées

La méthode la plus fréquente pour parcourir tout un dictionnaire est à base de la méthode items; voici par exemple comment on pourrait afficher le contenu :

3.10. DICTIONNAIRES 41

```
alice, age 30 eric, age 39 bob, age 42
```

On remarque d'abord que les entrées sont listées dans le désordre, plus précisément, il n'y a pas de notion d'ordre dans un dictionnaire; ceci est dû à l'action de la fonction de hachage, que nous avons vue dans la vidéo précédente.

On peut obtenir séparément la liste des clés et des valeurs avec :

La fonction len

On peut comme d'habitude obtenir la taille d'un dictionnaire avec la fonction len :

```
In [13]: print(f"{len(annuaire)} entrées dans annuaire")
3 entrées dans annuaire
```

Pour en savoir plus sur le type dict

Pour une liste exhaustive reportez-vous à la page de la documentation Python ici :

https://docs.python.org/3/library/stdtypes.html#mapping-types-dict

3.10.2 Complément - niveau intermédiaire

La méthode update

On peut également modifier un dictionnaire avec le contenu d'un autre dictionnaire avec la méthode update :

collections.OrderedDict: dictionnaire et ordre d'insertion

Attention : un dictionnaire est **non ordonné!** Il ne se souvient pas de l'ordre dans lequel les éléments ont été insérés. C'était particulièrement visible dans les versions de Python jusque 3.5 :

```
In []: %%python2

# cette cellule utilise python-2.7 pour illustrer le fait
# que les dictionnaires ne sont pas ordonnés

d = {'c' : 3, 'b' : 1, 'a' : 2}
for k, v in d.items():
    print k, v
```

En réalité, et depuis la version 3.6 de Python, il se trouve qu'**incidemment** l'implémentation CPython (la plus répandue donc) a été modifiée, et maintenant on peut avoir l'**impression** que les dictionnaires sont ordonnés :

Il faut insister sur le fait qu'il s'agit d'un **détail d'implémentation**, et que vous ne devez pas écrire du code qui suppose que les dictionnaires sont ordonnés.

Si vous avez besoin de dictionnaires qui sont **garantis** ordonnés, voyez dans le module collections la classe OrderedDict, qui est une personnalisation (une sous-classe) du type dict, qui cette fois possède cette bonne propriété:

3.10. DICTIONNAIRES 43

```
In [18]: from collections import OrderedDict
    d = OrderedDict()
    for i in ['a', 7, 3, 'x']:
        d[i] = i
    for k, v in d.items():
        print('OrderedDict', k, v)

OrderedDict a a
OrderedDict 7 7
OrderedDict 3 3
OrderedDict x x
```

collections.defaultdict:initialisation automatique

Imaginons que vous devez gérer un dictionnaire dont les valeurs sont des listes, et que votre programme ajoute des valeurs au fur et à mesure dans ces listes.

Avec un dictionnaire de base, cela peut vous amener à écrire un code qui ressemble à ceci :

```
In [19]: # imaginons qu'on a lu dans un fichier des couples (x, y)
         tuples = [
             (1, 2),
             (2, 1),
             (1, 3),
             (2, 4),
         1
In [20]: # et on veut construire un dictionnaire
         # x \rightarrow [liste de tous les y connectés à x]
         resultat = {}
         for x, y in tuples:
             if x not in resultat:
                 resultat[x] = []
             resultat[x].append(y)
         for key, value in resultat.items():
             print(key, value)
1 [2, 3]
2 [1, 4]
```

Cela fonctionne, mais n'est pas très élégant. Pour simplifier ce type de traitement, vous pouvez utiliser defaultdict, une sous-classe de dict dans le module collections :

```
In [21]: from collections import defaultdict
    # on indique que les valeurs doivent être créées à la volée
    # en utilisant la fonction list
    resultat = defaultdict(list)
```

Cela fonctionne aussi avec le type int, lorsque vous voulez par exemple compter des occurrences :

```
In [22]: compteurs = defaultdict(int)
         phrase = "une phrase dans laquelle on veut compter les caractères"
         for c in phrase:
             compteurs[c] += 1
         sorted(compteurs.items())
Out[22]: [(' ', 8),
          ('a', 5),
          ('c', 3),
          ('d', 1),
          ('e', 8),
          ('h', 1),
          ('1', 4),
          ('m', 1),
          ('n', 3),
          ('o', 2),
          ('p', 2),
          ('q', 1),
          ('r', 4),
          ('s', 4),
          ('t', 3),
          ('u', 3),
          ('v', 1),
          ('è', 1)]
```

Signalons enfin une fonctionnalité un peu analogue, quoiqu'un peut moins élégante à mon humble avis, mais qui est présente avec les dictionnaires dict standard. Il s'agit de la méthode setdefault qui permet, en un seul appel, de retourner la valeur associée à une clé et de créer cette clé au besoin, c'est-à-dire si elle n'est pas encore présente :

Notez bien que setdefault peut éventuellement créer une entrée mais ne **modifie jamais** la valeur associée à une clé déjà présente dans le dictionnaire, comme le nom le suggère d'ailleurs.

3.10.3 Complément - niveau avancé

Pour bien appréhender les dictionnaires, il nous faut souligner certaines particularités, à propos de la valeur de retour des méthodes comme items(), keys() et values().

Ce sont des objets itérables

Les méthodes items(), keys() et values() ne retournent pas des listes (comme c'était le cas en Python 2), mais des **objets itérables** :

Comme ce sont des itérables, on peut naturellement faire un for avec, on l'a vu :

Et un test d'appartenance avec in :

```
In [29]: print('a' in keys)
True
In [30]: print('x' in keys)
```

False

Mais ce ne sont pas des listes

```
In [31]: isinstance(keys, list)
Out[31]: False
```

Ce qui signifie qu'on n'a **pas alloué de mémoire** pour stocker toutes les clés, mais seulement un objet qui ne prend pas de place, ni de temps à construire :

```
In [32]: # construisons un dictionnaire
# pour anticiper un peu sur la compréhension de dictionnaire

big_dict = {k : k**2 for k in range(1_000_000)}

In [33]: %%timeit -n 10000
# créer un objet vue est très rapide
big_keys = big_dict.keys()

193 ns ± 51 ns per loop (mean ± std. dev. of 7 runs, 10000 loops each)

In [34]: # on répète ici car timeit travaille dans un espace qui lui est propre
# et donc on n'a pas défini big_keys pour notre interpréteur
big_keys = big_dict.keys()

In [35]: %%timeit -n 20
# si on devait vraiment construire la liste ce serait beaucoup plus long
big_lkeys = list(big_keys)

20.1 ms ± 391 µs per loop (mean ± std. dev. of 7 runs, 20 loops each)
```

En fait ce sont des *vues* Une autre propriété un peu inattendue de ces objets, c'est que **ce sont des vues**; ce qu'on veut dire par là (pour ceux qui connaissent, cela fait fait référence à la notion de vue dans les bases de données) c'est que la vue *voit* les changements fait sur l'objet dictionnaire *même après sa création* :

3.10. DICTIONNAIRES 47

a b c

Reportez vous à la section sur les vues de dictionnaires pour plus de détails.

Python 2 Ceci est naturellement en fort contraste avec tout ce qui se passait en Python 2, où l'on avait des méthodes distinctes, par exemple keys(), iterkeys() et viewkeys(), selon le type d'objets que l'on souhaitait construire.

3.11 Clés immuables

3.11.1 Complément - niveau intermédiaire

Nous avons vu comment manipuler un dictionnaire, il nous reste à voir un peu plus en détail les contraintes qui sont mises par le langage sur ce qui peut servir de clé dans un dictionnaire. On parle dans ce complément spécifiquement des clefs construites à partir des types built-in. Le cas de vos propres classes utilisées comme clefs de dictionnaires n'est pas abordé dans ce complément.

Une clé doit être immuable

Si vous vous souvenez de la vidéo sur les tables de hash, la mécanique interne du dictionnaire repose sur le calcul, à partir de chaque clé, d'une fonction de hachage.

C'est-à-dire que, pour simplifier, on localise la présence d'une clé en calculant d'abord f(cl) = hash

puis on poursuit la recherche en utilisant *hash* comme indice dans le tableau contenant les couples (clé, valeur).

On le rappelle, c'est cette astuce qui permet de réaliser les opérations sur les dictionnaires en temps constant - c'est-à-dire indépendamment du nombre d'éléments.

Cependant, pour que ce mécanisme fonctionne, il est indispensable que **la valeur de la clé reste inchangée** pendant la durée de vie du dictionnaire. Sinon, bien entendu, on pourrait avoir le scénario suivant :

- on range un tuple (clef, valeur) à un premier indice $f(clef) = hash_1$;
- on modifie la valeur de clef qui devient clef';
- on recherche notre valeur à l'indice $f(clef') = hash_2 \neq hash_1$.

et donc, avec ces hypothèses, on n'a plus la garantie de bon fonctionnement de la logique.

Une clé doit être globalement immuable

Nous avons depuis le début du cours longuement insisté sur le caractère mutable ou immuable des différents types prédéfinis de Python. Vous devez donc à présent avoir au moins en partie ce tableau en tête :

Туре	Mutable?
int,float	immuable
complex,bool	immuable
str	immuable
list	mutable
dict	mutable
set	mutable
frozenset	immuable

Le point important ici, est qu'il ne suffit pas, pour une clé, d'être de type immuable.

On peut le voir sur un exemple très simple; donnons-nous donc un dictionnaire :

```
In [1]: d = {}
```

Et commençons avec un objet de type immuable, un tuple d'entiers :

```
In [2]: bonne_cle = (1, 2)
```

Cet objet est non seulement **de type immuable**, mais tous ses composants et souscomposants sont **immuables**, on peut donc l'utiliser comme clé dans le dictionnaire :

Si à présent on essaie d'utiliser comme clé un tuple qui contient une liste :

```
In [4]: mauvaise_cle = (1, [1, 2])
```

Il se trouve que cette clé, **bien que de type immuable**, peut être **indirectement modifiée** puisque :

Et c'est pourquoi on ne peut pas utiliser cet objet comme clé dans le dictionnaire :

Pour conclure, il faut retenir qu'un objet n'est éligible pour être utilisé comme clé que s'il est **composé de types immuables de haut en bas** de la structure de données.

La raison d'être principale du type tuple, que nous avons vu la semaine passée, et du type frozenset, que nous verrons très prochainement, est précisément de construire de tels objets globalement immuables.

Épilogue

Tout ceci est valable pour les types *built-in*. Nous verrons que pour les types définis par l'utilisateur - les classes donc - que nous effleurons à la fin de cette semaine et que nous étudions plus en profondeur en semaine 6, c'est un autre mécanisme qui est utilisé pour calculer la clé de hachage d'une instance de classe.

3.12 Gérer des enregistrements

3.12.1 Complément - niveau intermédiaire

Implémenter un enregistrement comme un dictionnaire

Il nous faut faire le lien entre dictionnaire Python et la notion d'enregistrement, c'est-à-dire une donnée composite qui contient plusieurs champs. (À cette notion correspond, selon les langages, ce qu'on appelle un struct ou un record.)

Imaginons qu'on veuille manipuler un ensemble de données concernant des personnes; chaque personne est supposée avoir un nom, un âge et une adresse mail.

Il est possible, et assez fréquent, d'utiliser le dictionnaire comme support pour modéliser ces données comme ceci :

Bon, très bien, nous avons nos données, il est facile de les utiliser.

Par exemple, pour l'anniversaire de Pierre on fera :

```
In [2]: personnes[0]['age'] += 1
   Ce qui nous donne :
In [3]: for personne in personnes:
            print(10*"=")
            for info, valeur in personne.items():
                print(f"{info} -> {valeur}")
=======
nom -> Pierre
age -> 26
email -> pierre@example.com
========
nom -> Paul
age -> 18
email -> paul@example.com
=======
nom -> Jacques
age -> 52
email -> jacques@example.com
```

Un dictionnaire pour indexer les enregistrements

Cela dit, il est bien clair que cette façon de faire n'est pas très pratique; pour marquer l'anniversaire de Pierre on ne sait bien entendu pas que son enregistrement est le premier dans la liste. C'est pourquoi il est plus adapté, pour modéliser ces informations, d'utiliser non

pas une liste, mais à nouveau... un dictionnaire.

Si on imagine qu'on a commencé par lire ces données séquentiellement dans un fichier, et qu'on a calculé l'objet personnes comme la liste qu'on a vue ci-dessus, alors il est possible de construire un index de ces dictionnaires, (un dictionnaire de dictionnaires, donc).

C'est-à-dire, en anticipant un peu sur la construction de dictionnaires par compréhension :

Attardons-nous un tout petit peu; nous avons construit un dictionnaire par compréhension, en créant autant d'entrées que de personnes. Nous aborderons en détail la notion de compréhension de sets et de dictionnaires en semaine 5, donc si cette notation vous paraît étrange pour le moment, pas d'inquiétude.

Le résultat est donc un dictionnaire qu'on peut afficher comme ceci :

Dans cet exemple, le premier niveau de dictionnaire permet de trouver rapidement un objet à partir d'un nom; dans le second niveau au contraire on utilise le dictionnaire pour implémenter un enregistrement, à la façon d'un struct en C.

Techniques similaires

Notons enfin qu'il existe aussi, en Python, un autre mécanisme qui peut être utilisé pour gérer ce genre d'objets composites, ce sont les classes que nous verrons en semaine 6, et qui permettent de définir de nouveaux types plutôt que, comme nous l'avons fait ici, d'utiliser un type prédéfini. Dans ce sens, l'utilisation d'une classe permet davantage de souplesse, au prix de davantage d'effort.

3.12.2 Complément - niveau avancé

La même idée, mais avec une classe Personne

Je vais donner ici une implémentation du code ci-dessus, qui utilise une classe pour modéliser les personnes. Naturellement je n'entre pas dans les détails, que l'on verra en semaine 6, mais j'espère vous donner un aperçu des classes dans un usage réaliste, et vous montrer les avantages de cette approche.

Pour commencer je définis la classe Personne, qui va me servir à modéliser chaque personne :

```
In [7]: class Personne:
            # le constructeur - vous ignorez le paramètre self,
             # on pourra construire une personne à partir de
             # 3 paramètres
            def __init__(self, nom, age, email):
                self.nom = nom
                self.age = age
                self.email = email
            # je définis cette méthode pour avoir
             # quelque chose de lisible quand je print()
            def __repr__(self):
                return f"{self.nom} ({self.age} ans) sur {self.email}"
   Pour construire ma liste de personnes, je fais alors :
In [8]: personnes2 = [
            Personne('Pierre', 25, 'pierre@example.com'),
            Personne('Paul', 18, 'paul@example.com'),
            Personne('Jacques', 52, 'jacques@example.com'),
   Si je regarde un élément de la liste j'obtiens :
In [9]: personnes2[0]
Out[9]: Pierre (25 ans) sur pierre@example.com
  Je peux indexer tout ceci comme tout à l'heure, si j'ai besoin d'un accès rapide :
In [10]: # je dois utiliser cette fois personne.nom et non plus personne['nom']
         index2 = {personne.nom : personne for personne in personnes2}
   Le principe ici est exactement identique à ce qu'on a fait avec le dictionnaire de diction-
naires, mais on a construit un dictionnaire d'instances.
   Et de cette façon:
In [11]: print(index2['Pierre'])
Pierre (25 ans) sur pierre@example.com
```

Rendez-vous en semaine 6 pour approfondir la notion de classes et d'instances.

3.13 Dictionnaires et listes

3.13.1 Exercice - niveau basique

```
In [ ]: from corrections.exo_graph_dict import exo_graph_dict
```

On veut implémenter un petit modèle de graphes. Comme on a les données dans des fichiers, on veut analyser des fichiers d'entrée qui ressemblent à ceci :

```
In []: !cat data/graph1.txt
qui signifierait:
— un graphe à 3 sommets s1, s2 et s3;
— et 4 arêtes
— une entre s1 et s2 de longueur 10;
— une entre s2 et s3 de longueur 12;
— etc...
```

On vous demande d'écrire une fonction qui lit un tel fichier texte, et construit (et retourne) un dictionnaire Python qui représente ce graphe.

Dans cet exercice on choisit:

- de modéliser le graphe comme un dictionnaire indexé sur les (noms de) sommets;
- et chaque valeur est une liste de tuples de la forme (*suivant*, *longueur*), dans l'ordre d'apparition dans le fichier d'entrée.

Notes

- Vous remarquerez que l'exemple ci-dessus retourne un dictionnaire standard; une solution qui utiliserait defaultdict est acceptable également;
- Notez bien également que dans le résultat, la longueur d'un arc est attendue comme un int.

3.14 Fusionner des données

3.14.1 Exercices

Cet exercice vient en deux versions, une de niveau basique et une de niveau intermédiaire.

La version basique est une application de la technique d'indexation que l'on a vue dans le complément "Gérer des enregistrements". On peut très bien faire les deux versions dans l'ordre, une fois qu'on a fait la version basique on est en principe un peu plus avancé pour aborder la version intermédiaire.

Contexte

Nous allons commencer à utiliser des données un peu plus réalistes. Il s'agit de données obtenues auprès de MarineTraffic - et légèrement simplifiées pour les besoins de l'exercice. Ce site expose les coordonnées géographiques de bateaux observées en mer au travers d'un réseau de collecte de type *crowdsourcing*.

De manière à optimiser le volume de données à transférer, l'API de MarineTraffic offre deux modes pour obtenir les données :

- **mode étendu** : chaque mesure (bateau x position x temps) est accompagnée de tous les détails du bateau (id, nom, pays de rattachement, etc.);
- **mode abrégé** : chaque mesure est uniquement attachée à l'id du bateau.

En effet, chaque bateau possède un identifiant unique qui est un entier, que l'on note id.

Chargement des données

Commençons par charger les données de l'exercice :

```
In [ ]: from corrections.exo_marine_dict import extended, abbreviated
```

Format des données

Le format de ces données est relativement simple, il s'agit dans les deux cas d'une liste d'entrées - une par bateau.

Chaque entrée à son tour est une liste qui contient :

```
mode étendu: [id, latitude, longitude, date_heure, nom_bateau, code_pays, ...] mode abrégé: [id, latitude, longitude, date_heure]
```

sachant que les entrées après le code pays dans le format étendu ne nous intéressent pas pour cet exercice.

On précise également que les deux listes extended et abbreviated :

- possèdent exactement le même nombre d'entrées;
- et correspondent aux mêmes bateaux;
- mais naturellement à des moments différents;
- et pas forcément dans le même ordre.

Exercice - niveau basique

But de l'exercice On vous demande d'écrire une fonction index qui calcule, à partir de la liste des données étendues, un dictionnaire qui est :

- indexé par l'id de chaque bateau;
- et qui a pour valeur la liste qui décrit le bateau correspondant.

De manière plus imagée, si :

```
extended = [ bateau1, bateau2, ... ]
  Et si:
bateau1 = [ id1, latitude, ... ]
  On doit obtenir comme résultat de index un dictionnaire:
{
  id1 -> [ id_bateau1, latitude, ... ],
  id2 ... }
```

Bref, on veut pouvoir retrouver les différents éléments de la liste extended par accès direct, en ne faisant qu'une seule recherche dans l'index.

```
In []: # le résultat attendu
    result_index = exo_index.resultat(extended)

# on en profite pour illustrer le module pprint
from pprint import pprint

# à quoi ressemble le résultat pour un bateau au hasard
for key, value in result_index.items():
    print("==== clé")
    pprint(key)
    print("==== valeur")
    pprint(value)
    break
```

Remarquez ci-dessus l'utilisation d'un utilitaire parfois pratique : le module pprint pour pretty-printer.

Votre code

Validation

```
In [ ]: exo_index.correction(index, abbreviated)
```

Vous remarquerez d'ailleurs que la seule chose que l'on utilise dans cet exercice, c'est que l'id des bateaux arrive en première position (dans la liste qui matérialise le bateau), aussi votre code doit marcher à l'identique avec les bateaux étendus :

```
In []: exo_index.correction(index, extended)
```

Exercice - niveau intermédiaire

But de l'exercice On vous demande d'écrire une fonction merge qui fasse une consolidation des données, de façon à obtenir en sortie un dictionnaire :

```
id -> [nom_bateau, code_pays, position_etendu, position_abrege]
```

dans lequel les deux objets position sont tous les deux des tuples de la forme :

```
(latitude, longitude, date_heure)
```

Voici par exemple un couple clé-valeur dans le résultat attendu :

```
In []: # le résultat attendu
    result_merge = exo_merge.resultat(extended, abbreviated)

# à quoi ressemble le résultat pour un bateau au hasard
    from pprint import pprint
    for key_value in result_merge.items():
        pprint(key_value)
        break
```

Votre code

Validation

```
In [ ]: exo_merge.correction(merge, extended, abbreviated)
```

Les fichiers de données complets

Signalons enfin pour ceux qui sont intéressés que les données chargées dans cet exercice sont disponibles au format JSON - qui est précisément celui exposé par marinetraffic.

Nous avons beaucoup simplifié les données d'entrée pour vous permettre une mise au point plus facile. Si vous voulez vous amuser à charger des données un peu plus significatives, sachez que :

— vous avez accès aux fichiers de données plus complets :

```
— data/marine-e1-ext.json
— data/marine-e1-abb.json
```

— pour charger ces fichiers, qui sont donc au format JSON, la connaissance intime de ce format n'est pas nécessaire, on peut tout simplement utiliser le module j son. Voici le code utilisé dans l'exercice pour charger ces JSON en mémoire; il utilise des notions que nous verrons dans les semaines à venir :

```
In []: # load data from files
    import json

with open("data/marine-e1-ext.json", encoding="utf-8") as feed:
    extended_full = json.load(feed)

with open("data/marine-e1-abb.json", encoding="utf-8") as feed:
    abbreviated_full = json.load(feed)
```

Une fois que vous avez un code qui fonctionne vous pouvez le lancer sur ces données plus copieuses en faisant :

```
In [ ]: exo_merge.correction(merge, extended_full, abbreviated_full)
```

3.15 Ensembles

3.15.1 Complément - niveau basique

Ce document résume les opérations courantes disponibles sur le type set. On rappelle que le type set est un type **mutable**.

Création en extension

On crée un ensemble avec les accolades, comme les dictionnaires, mais sans utiliser le caractère :, et cela donne par exemple :

Création - la fonction set

Il devrait être clair à ce stade que, le nom du type étant set, la fonction set est un constructeur d'ensemble. On aurait donc aussi bien pu faire :

Créer un ensemble vide

Il faut remarquer que l'on ne peut pas créer un ensemble vide en extension. En effet :

```
In [3]: type({})
Out[3]: dict
```

Ceci est lié à des raisons historiques, les ensembles n'ayant fait leur apparition que tardivement dans le langage en tant que citoyen de première classe.

Pour créer un ensemble vide, la pratique la plus courante est celle-ci :

Ou également, moins élégant mais que l'on trouve parfois dans du vieux code :

3.15. ENSEMBLES 59

Un élément dans un ensemble doit être globalement immuable

On a vu précédemment que les clés dans un dictionnaire doivent être globalement immuables. Pour exactement les mêmes raisons, les éléments d'un ensemble doivent aussi être globalement immuables :

```
# on ne peut pas insérer un tuple qui contient une liste
>>> ensemble = {(1, 2, [3, 4])}
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: unhashable type: 'list'
```

Le type set étant lui-même mutable, on ne peut pas créer un ensemble d'ensembles :

```
>>> ensemble = {{1, 2}}
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: unhashable type: 'set'
```

Et c'est une des raisons d'être du type frozenset.

Création - la fonction frozenset

Un frozenset est un ensemble qu'on ne peut pas modifier, et qui donc peut servir de clé dans un dictionnaire, ou être inclus dans un autre ensemble (mutable ou pas).

Il n'existe pas de raccourci syntaxique comme les {} pour créer un ensemble immuable, qui doit être créé avec la fonction frozenset. Toutes les opérations documentées dans ce notebook, et qui n'ont pas besoin de modifier l'ensemble, sont disponibles sur un frozenset.

Parmi les fonctions exclues sur un frozenset, on peut citer : update, pop, clear, remove ou discard.

Opérations simples

Manipulations

```
In [9]: ensemble = \{1, 2, 1\}
        ensemble
Out[9]: {1, 2}
In [10]: # pour nettoyer
         ensemble.clear()
         ensemble
Out[10]: set()
In [11]: # ajouter un element
         ensemble.add(1)
         ensemble
Out[11]: {1}
In [12]: # ajouter tous les elements d'un autre *ensemble*
         ensemble.update({2, (1, 2, 3), (1, 3, 5)})
         ensemble
Out[12]: {(1, 2, 3), (1, 3, 5), 1, 2}
In [13]: # enlever un element avec discard
         ensemble.discard((1, 3, 5))
         ensemble
Out[13]: {(1, 2, 3), 1, 2}
In [14]: # discard fonctionne même si l'élément n'est pas présent
         ensemble.discard('foo')
         ensemble
Out[14]: {(1, 2, 3), 1, 2}
In [15]: # enlever un élément avec remove
         ensemble.remove((1, 2, 3))
         ensemble
Out[15]: {1, 2}
In [16]: # contrairement à discard, l'élément doit être présent,
         # sinon il y a une exception
         try:
             ensemble.remove('foo')
         except KeyError as e:
             print("remove a levé l'exception", e)
remove a levé l'exception 'foo'
```

3.15. ENSEMBLES 61

La capture d'exception avec try et except sert à capturer une erreur d'exécution du programme (que l'on appelle exception) pour continuer le programme. Le but de cet exemple est simplement de montrer (d'une manière plus élégante que de voir simplement le programme planter avec une exception non capturée) que l'expression ensemble.remove('foo') génère une exception. Si ce concept vous paraît obscur, pas d'inquiétude, nous l'aborderons cette semaine et nous y reviendrons en détail en semaine 6.

Opérations classiques sur les ensembles

Donnons-nous deux ensembles simples :

N'oubliez pas que les ensembles, comme les dictionnaires, ne sont pas ordonnés.

Remarques:

- les notations des opérateurs sur les ensembles rappellent les opérateurs "bit-à-bit" sur les entiers;
- ces opérateurs sont également disponibles sous la forme de méthodes.

Union

```
In [19]: A2 | A3
Out[19]: {0, 2, 3, 4, 6}
    Intersection
In [20]: A2 & A3
Out[20]: {0, 6}
```

```
Différence
```

```
In [21]: A2 - A3
Out[21]: {2, 4}
In [22]: A3 - A2
Out[22]: {3}
   Différence symétrique On rappelle que A\Delta B = (A - B) \cup (B - A)
In [23]: A2 ^ A3
Out[23]: {2, 3, 4}
Comparaisons
   Ici encore on se donne deux ensembles:
In [24]: superset = \{0, 1, 2, 3\}
         print('superset', superset)
         subset = \{1, 3\}
         print('subset', subset)
superset {0, 1, 2, 3}
subset \{1, 3\}
   Égalité
In [25]: heteroclite == heteroclite2
Out[25]: True
   Inclusion
In [26]: subset <= superset</pre>
Out[26]: True
In [27]: subset < superset</pre>
Out[27]: True
In [28]: heteroclite < heteroclite2</pre>
Out[28]: False
   Ensembles disjoints
In [29]: heteroclite.isdisjoint(A3)
Out[29]: True
```

Pour en savoir plus

Reportez vous à la section sur les ensembles dans la documentation Python.

3.16. ENSEMBLES 63

3.16 Ensembles

3.16.1 Exercice - niveau basique

On se propose d'écrire une fonction read_set qui construit un ensemble à partir du contenu d'un fichier. Voici par exemple un fichier d'entrée :

```
In [ ]: !cat data/setref1.txt
```

read_set va prendre en argument un nom de fichier (vous pouvez supposer qu'il existe), enlever les espaces éventuelles au début et à la fin de chaque ligne, et construire un ensemble de toutes les lignes; par exemple :

3.16.2 Deuxième partie - niveau basique

Ceci étant acquis, on veut écrire une deuxième fonction search_in_set qui prend en argument deux fichiers :

- filename_reference est le nom d'un fichier contenant des mots de référence;
- filename est le nom d'un fichier contenant des mots, dont on veut savoir s'ils sont ou non dans les références.

Pour cela search_in_set doit retourner une liste, contenant pour chaque ligne du fichier filename un tuple avec :

- la ligne (sans les espaces de début et de fin, ni la fin de ligne);
- un booléen qui indique si ce mot est présent dans les références ou pas.

Par exemple:

3.17 Exercice sur les ensembles

3.17.1 Exercice - niveau intermédiaire

Les données

Nous reprenons le même genre de données marines en provenance de MarineTraffic que nous avons vues dans l'exercice précédent.

```
In [ ]: from corrections.exo_marine_set import abbreviated, extended
```

Rappels sur les formats

```
étendu: [id, latitude, longitude, date_heure, nom_bateau, code_pays...]
abrégé: [id, latitude, longitude, date_heure]

In []: print(extended[0])

In []: print(abbreviated[0])
```

But de l'exercice

Notez bien une différence importante avec l'exercice précédent : cette fois **il n'y a plus correspondance** entre les bateaux rapportés dans les données étendues et abrégées.

Le but de l'exercice est précisément d'étudier la différence, et pour cela on vous demande d'écrire une fonction

```
diff(extended, abbreviated)
```

qui retourne un tuple à trois éléments :

- l'ensemble (set) des **noms** des bateaux présents dans extended mais pas dans abbreviated;
- l'ensemble des **noms** des bateaux présents dans extended et dans abbreviated;
- l'ensemble des **id** des bateaux présents dans abbreviated mais pas dans extended (par construction, les données ne nous permettent pas d'obtenir les noms de ces bateaux).

```
In []: # le résultat attendu
    result = exo_diff.resultat(extended, abbreviated)

# combien de bateaux sont concernés
    def show_result(extended, abbreviated, result):
        """

        Affiche divers décomptes sur les arguments
        en entrée et en sortie de diff
        """
        print(10*'-', "Les entrées")
```

```
print(f"Dans extended: {len(extended)} entrées")
print(f"Dans abbreviated: {len(abbreviated)} entrées")
print(10*'-', "Le résultat du diff")
extended_only, both, abbreviated_only = result
print(f"Dans extended mais pas dans abbreviated {len(extended_only)}")
print(f"Dans les deux {len(both)}")
print(f"Dans abbreviated mais pas dans extended {len(abbreviated_only)}")
show_result(extended, abbreviated, result)
```

Votre code

Validation

```
In []: exo_diff.correction(diff, extended, abbreviated)
```

Des fichiers de données plus réalistes

Comme pour l'exercice précédent, les données fournies ici sont très simplistes; vous pouvez, si vous le voulez, essayer votre code avec des données (un peu) plus réalistes en chargeant des fichiers de données plus complets :

```
— data/marine-e2-ext.json
 — data/marine-e2-abb.json
   Ce qui donnerait en Python :
In []: # load data from files
        import json
        with open("data/marine-e2-ext.json", encoding="utf-8") as feed:
            extended_full = json.load(feed)
        with open("data/marine-e2-abb.json", encoding="utf-8") as feed:
            abbreviated_full = json.load(feed)
In []: # le résultat de votre fonction sur des données plus vastes
        # attention, show_result fait des hypothèses sur le type de votre résultat
        # aussi si vous essayez d'exécuter ceci avec comme fonction diff
        # la version vide qui est dans le notebook original
        # cela peut provoquer une exception
        diff_full = diff(extended_full, abbreviated_full)
        show_result(extended_full, abbreviated_full, diff_full)
```

Je signale enfin à propos de ces données plus complètes que :

- on a supprimé les entrées correspondant à des bateaux différents mais de même nom; cette situation peut arriver dans la réalité (c'est pourquoi d'ailleurs les bateaux ont un *id*) mais ici ce n'est pas le cas;
- il se peut par contre qu'un même bateau fasse l'objet de plusieurs mesures dans extended et/ou dans abbreviated.

```
3.18 try ... else ... finally
```

3.18.1 Complément - niveau intermédiaire

L'instruction try est généralement assortie d'une une ou plusieurs clauses except, comme on l'a vu dans la vidéo.

Sachez que l'on peut aussi utiliser - après toutes les clauses except :

- une clause else, qui va être exécutée si aucune exception n'est attrapée;
- t/ou une clause finally qui sera alors exécutée quoi qu'il arrive.

Voyons cela sur des exemples.

finally

C'est sans doute finally qui est la plus utile de ces deux clauses, car elle permet de faire un nettoyage **dans tous les cas de figure** - de ce point de vue, cela rappelle un peu les *context managers*.

Et par exemple, comme avec les *context managers*, une fonction peut faire des choses même après un return.

```
In [1]: # une fonction qui fait des choses après un return
        def return_with_finally(number):
            try:
                return 1/number
            except ZeroDivisionError as e:
                print(f"00PS, {type(e)}, {e}")
                return("zero-divide")
            finally:
                print("on passe ici même si on a vu un return")
In [2]: # sans exception
       return_with_finally(1)
on passe ici même si on a vu un return
Out[2]: 1.0
In [3]: # avec exception
       return_with_finally(0)
OOPS, <class 'ZeroDivisionError'>, division by zero
on passe ici même si on a vu un return
Out[3]: 'zero-divide'
```

else

La logique ici est assez similaire, sauf que le code du else n'est exécuté que dans le cas où aucune exception n'est attrapée.

En première approximation, on pourrait penser que c'est équivalent de mettre du code dans la clause else ou à la fin de la clause try. En fait il y a une différence subtile :

The use of the else clause is better than adding additional code to the try clause because it avoids accidentally catching an exception that wasn't raised by the code being protected by the try... except statement.

Dit autrement, si le code dans la clause else lève une exception, celle-ci ne **sera pas attrapée** par le try courant, et sera donc propagée.

Voici un exemple rapide, en pratique on rencontre assez peu souvent une clause else dans un try :

```
In [4]: # pour montrer la clause else dans un usage banal
        def function_with_else(number):
            try:
                x = 1/number
            except ZeroDivisionError as e:
                print(f"00PS, {type(e)}, {e}")
            else:
                print("on passe ici seulement avec un nombre non nul")
            return 'something else'
In [5]: # sans exception
        function_with_else(1)
on passe ici seulement avec un nombre non nul
Out[5]: 'something else'
In [6]: # avec exception
        function_with_else(0)
OOPS, <class 'ZeroDivisionError'>, division by zero
Out[6]: 'something else'
   Remarquez que else ne présente pas cette particularité de "traverser" le return, que l'on
a vue avec finally:
In [7]: # la clause else ne traverse pas les return
        def return_with_else(number):
            try:
                return 1/number
            except ZeroDivisionError as e:
                print(f"00PS, {type(e)}, {e}")
                return("zero-divide")
            else:
```

print("on ne passe jamais ici à cause des return")

Pour en savoir plus

Voyez le tutorial sur les exceptions dans la documentation officielle.

3.19 L'opérateur is

3.19.1 Complément - niveau basique

```
In [ ]: %load_ext ipythontutor
```

Les opérateurs is et ==

- nous avons déjà parlé de l'opérateur == qui compare la valeur de deux objets;
- python fournit aussi un opérateur is qui permet de savoir si deux valeurs correspondent **au même objet** en mémoire.

Nous allons illustrer la différence entre ces deux opérateurs.

Scénario 1

Scénario 2

La même chose sous pythontutor

Scénario 1

Utilisez is plutôt que == lorsque c'est possible

La pratique usuelle est d'utiliser is lorsqu'on compare avec un objet qui est un singleton, comme typiquement None.

Par exemple on préfèrera écrire :

a = b = [1, 2]

Qui se comporte de la même manière (à nouveau, parce qu'on compare avec None), mais est légèrement moins lisible, et franchement moins pythonique. :)

Notez aussi et surtout que is est **plus efficace** que ==. En effet is peut être évalué en temps constant, puisqu'il s'agit essentiellement de comparer les deux adresses. Alors que pour == il peut s'agir de parcourir toute une structure de données possiblement très complexe.

3.19.2 Complément - niveau intermédiaire

La fonction id

Pour bien comprendre le fonctionnement de is nous allons voir la fonction id qui retourne un identificateur unique pour chaque objet; un modèle mental acceptable est celui d'adresse mémoire.

```
In [7]: id(True)
```

```
Out[7]: 1924796304
```

Comme vous vous en doutez, l'opérateur is peut être décrit formellement à partir de id comme ceci :

```
(a is b) \iff (id(a) == id(b))
```

Certains types de base sont des singletons

Un singleton est un objet qui n'existe qu'en un seul exemplaire dans la mémoire. Un usage classique des singletons en Python est de minimiser le nombre d'objets immuables en mémoire. Voyons ce que cela nous donne avec des entiers :

Tiens, c'est curieux, nous avons ici deux objets, que l'on pourrait penser différents, mais en fait ce sont les mêmes; a et b désignent **le même objet** python, et on a :

```
In [9]: a is b
Out[9]: True
```

Il se trouve que, dans le cas des petits entiers, python réalise une optimisation de l'utilisation de la mémoire. Quel que soit le nombre de variables dont la valeur est 3, un seul objet correspondant à l'entier 3 est alloué et créé, pour éviter d'engorger la mémoire. On dit que l'entier 3 est implémenté comme un singleton; nous reverrons ceci en exercice.

On trouve cette optimisation avec quelques autres objets python, comme par exemple :

```
In [10]: a = ""
b = ""
a is b

Out[10]: True
```

Ou encore, plus surprenant :

Conclusion cette optimisation ne touche aucun type mutable (heureusement); pour les types immuables, il n'est pas extrêmement important de savoir en détail quels objets sont implémentés de la sorte.

Ce qui est par contre extrêmement important est de comprendre la différence entre is et ==, et de les utiliser à bon escient au risque d'écrire du code fragile.

Pour en savoir plus

Aux étudiants de niveau avancé, nous recommandons la lecture de la section "Objects, values and types" dans la documentation Python :

https://docs.python.org/3/reference/datamodel.html#objects-values-and-types

qui aborde également la notion de "garbage collection", que nous n'aurons pas le temps d'approfondir dans ce MOOC.

3.20 Listes infinies & références circulaires

3.20.1 Complément - niveau intermédiaire

```
In [ ]: %load_ext ipythontutor
```

Nous allons maintenant construire un objet un peu abscons. Cet exemple précis n'a aucune utilité pratique, mais permet de bien comprendre la logique du langage.

Construisons une liste à un seul élément, peu importe quoi :

```
In [1]: infini_1 = [None]
```

À présent nous allons remplacer le premier et seul élément de la liste par... la liste ellemême :

Pour essayer de décrire l'objet liste ainsi obtenu, on pourrait dire qu'il s'agit d'une liste de taille 1 et de profondeur infinie, une sorte de fil infini en quelque sorte.

Naturellement, l'objet obtenu est difficile à imprimer de manière convaincante. Pour faire en sorte que cet objet soit tout de même imprimable, et éviter une boucle infinie, python utilise l'ellipse . . . pour indiquer ce qu'on appelle une référence circulaire. Si on n'y prenait pas garde en effet, il faudrait écrire [[[[etc.]]]] avec une infinité de crochets.

Voici la même séquence exécutée sous http://pythontutor.com; il s'agit d'un site très utile pour comprendre comment python implémente les objets, les références et les partages.

Cliquez sur le bouton Forward pour avancer dans l'exécution de la séquence. À la fin de la séquence vous verrez - ce n'est pas forcément clair - la seule cellule de la liste à se référencer elle-même :

```
In []: %%ipythontutor height=230
    infini_1 = [None]
    infini_1[0] = infini_1
```

Toutes les fonctions de python ne sont pas aussi intelligentes que print. Bien qu'on puisse comparer cette liste avec elle-même :

```
In [3]: infini_1 == infini_1
Out[3]: True
```

il n'en est pas de même si on la compare avec un objet analogue mais pas identique :

```
In [4]: infini_2 = [0]
    infini_2[0] = infini_2
    print(infini_2)
    infini_1 == infini_2
```

```
[[...]]
```

```
RecursionError Traceback (most recent call last)

<ipython-input-4-3c044c24fccb> in <module>()
    2 infini_2[0] = infini_2
    3 print(infini_2)
----> 4 infini_1 == infini_2
```

RecursionError: maximum recursion depth exceeded in comparison

Généralisation aux références circulaires

On obtient un phénomène équivalent dès lors qu'un élément contenu dans un objet fait référence à l'objet lui-même. Voici par exemple comment on peut construire un dictionnaire qui contient une référence circulaire :

On voit à nouveau réapparaître les ellipses, qui indiquent que pour chaque point, le nouveau champ points est un objet qui a déjà été imprimé.

Cette technique est cette fois très utile et très utilisée dans la pratique, dès lors qu'on a besoin de naviguer de manière arbitraire dans une structure de données compliquée. Dans cet exemple, pas très réaliste naturellement, on pourrait à présent accéder depuis un point à tous les autres points de la collection dont il fait partie.

À nouveau il peut être intéressant de voir le comportement de cet exemple avec http://pythontutor.com pour bien comprendre ce qui se passe, si cela ne vous semble pas clair à première vue :

3.21 Les différentes copies

```
In [ ]: %load_ext ipythontutor
```

3.21.1 Complément - niveau basique

Deux types de copie

Pour résumer les deux grands types de copie que l'on a vus dans la vidéo :

- La shallow copy de l'anglais shallow qui signifie superficiel;
- La deep copy de deep qui signifie profond.

Le module copy

Pour réaliser une copie, la méthode la plus simple, en ceci qu'elle fonctionne avec tous les types de manière identique, consiste à utiliser le module standard copy, et notamment :

- copy.copy pour une copie superficielle;
- copy.deepcopy pour une copie en profondeur.

Un exemple

Nous allons voir le résultat des deux formes de copie sur un même sujet de départ.

La copie superficielle / shallow copie / copy.copy

N'oubliez pas de cliquer le bouton Forward dans la fenêtre pythontutor :

Vous remarquez que :

- la source et la copie partagent tous leurs (sous-)éléments, et notamment la liste source [0] et l'ensemble source [1];
- ainsi, après cette copie, on peut modifier l'un de ces deux objets (la liste ou l'ensemble), et ainsi modifier la source **et** la copie.

On rappelle aussi que, la source étant une liste, on aurait pu aussi bien faire la copie superficielle avec

```
shallow2 = source[:]
```

La copie profonde / deep copie / copy.deepcopy Sur le même objet de départ, voici ce que fait la copie profonde :

Ici, il faut remarquer que:

- les deux objets mutables accessibles via source, c'est-à-dire la liste source[0] et l'ensemble source[1], ont été tous deux dupliqués;
- le tuple correspondant à source[2] n'est pas dupliqué, mais comme il n'est pas mutable on ne peut pas modifier la copie au travers de la source;
- de manière générale, on a la bonne propriété que la source et sa copie ne partagent rien qui soit modifiable;
- et donc on ne peut pas modifier l'un au travers de l'autre.

On retrouve donc à nouveau l'optimisation qui est mise en place dans python pour implémenter les types immuables comme des singletons lorsque c'est possible. Cela a été vu en détail dans le complément consacré à l'opérateur is.

3.21.2 Complément - niveau intermédiaire

```
In [2]: # on répète car le code précédent a seulement été exposé à pythontutor
    import copy
    source = [
        [1, 2, 3], # une liste
        {1, 2, 3}, # un ensemble
        (1, 2, 3), # un tuple
        '123', # un string
        123, # un entier
    ]
    shallow_copy = copy.copy(source)
    deep_copy = copy.deepcopy(source)
```

Objets égaux au sens logique

Bien sûr ces trois objets se ressemblent si on fait une comparaison *logique* avec == :

Inspectons les objets de premier niveau

Mais par contre si on compare **l'identité** des objets de premier niveau, on voit que source et shallow_copy partagent leurs objets :

```
In [4]: # voir la cellule ci-dessous si ceci vous parait peu clair
       for i, (source_item, copy_item) in enumerate(zip(source, shallow_copy)):
            compare = source_item is copy_item
            print(f"source[{i}] is shallow_copy[{i}] -> {compare}")
source[0] is shallow_copy[0] -> True
source[1] is shallow_copy[1] -> True
source[2] is shallow_copy[2] -> True
source[3] is shallow_copy[3] -> True
source[4] is shallow_copy[4] -> True
In [5]: # rappel au sujet de zip et enumerate
        # la cellule ci-dessous est essentiellement équivalente à
        for i in range(len(source)):
            compare = source[i] is shallow_copy[i]
            print(f"source[{i}] is shallow_copy[{i}] -> {compare}")
source[0] is shallow_copy[0] -> True
source[1] is shallow_copy[1] -> True
source[2] is shallow_copy[2] -> True
source[3] is shallow_copy[3] -> True
source[4] is shallow_copy[4] -> True
   Alors que naturellement ce n'est pas le cas avec la copie en profondeur :
In [6]: for i, (source_item, deep_item) in enumerate(zip(source, deep_copy)):
            compare = source_item is deep_item
            print(f"source[{i}] is deep_copy[{i}] -> {compare}")
source[0] is deep_copy[0] -> False
source[1] is deep_copy[1] -> False
source[2] is deep_copy[2] -> True
source[3] is deep_copy[3] -> True
```

On retrouve ici ce qu'on avait déjà remarqué sous pythontutor, à savoir que les trois derniers objets - immuables - n'ont pas été dupliqués comme on aurait pu s'y attendre.

On modifie la source

source[4] is deep_copy[4] -> True

Il doit être clair à présent que, précisément parce que deep_copy est une copie en profondeur, on peut modifier source sans impacter du tout deep_copy.

S'agissant de shallow_copy, par contre, seuls les éléments de premier niveau ont été copiés. Aussi si on fait une modification par exemple à **l'intérieur** de la liste qui est le premier fils de source, cela sera **répercuté** dans shallow_copy:

Si par contre on remplace complètement un élément de premier niveau dans la source, cela ne sera pas répercuté dans la copie superficielle :

Copie et circularité

Le module copy est capable de copier - même en profondeur - des objets contenant des références circulaires.

Pour en savoir plus

On peut se reporter à la section sur le module copy dans la documentation Python.

3.22 L'instruction del

3.22.1 Complément - niveau basique

Voici un récapitulatif sur l'instruction del selon le contexte dans lequel elle est utilisée.

Sur une variable

On peut annuler la définition d'une variable, avec del.

Pour l'illustrer, nous utilisons un bloc try ... except ... pour attraper le cas échéant l'exception NameError, qui est produite lorsqu'on référence une variable qui n'est pas définie.

```
In [1]: # la variable a n'est pas définie
        try:
            print('a=', a)
        except NameError as e:
            print("a n'est pas définie")
a n'est pas définie
In [2]: # on la définit
        a = 10
        # aucun souci ici, l'exception n'est pas levée
            print('a=', a)
        except NameError as e:
            print("a n'est pas définie")
a= 10
In [3]: # maintenant on peut effacer la variable
        del a
        # c'est comme si on ne l'avait pas définie
        # dans la cellule précédente
        try:
            print('a=', a)
        except NameError as e:
            print("a n'est pas définie")
a n'est pas définie
```

Sur une liste

On peut enlever d'une liste les éléments qui correspondent à une slice :

Sur un dictionnaire

Avec del on peut enlever une clé, et donc la valeur correspondante, d'un dictionnaire :

On peut passer plusieurs arguments à del

Pour en savoir plus

La page sur l'instruction del dans la documentation Python.

3.23 Affectation simultanée

3.23.1 Complément - niveau basique

Nous avons déjà parlé de l'affectation par *sequence unpacking* (en Semaine 3, séquence "Les tuples"), qui consiste à affecter à plusieurs variables des "morceaux" d'un objet, comme dans :

```
In [1]: x, y = ['spam', 'egg']
```

Dans ce complément nous allons voir une autre forme de l'affectation, qui consiste à affecter **le même objet** à plusieurs variables. Commençons par un exemple simple :

La raison pour laquelle nous abordons cette construction maintenant est qu'elle a une forte relation avec les références partagées; pour bien le voir, nous allons utiliser une valeur mutable comme valeur à affecter :

```
In [3]: # on affecte a et b au même objet liste vide a = b = []
```

Dès lors nous sommes dans le cas typique d'une référence partagée; une modification de a va se répercuter sur b puisque ces deux variables désignent **le même objet** :

Ceci est à mettre en contraste avec plusieurs affectations séparées :

```
In [5]: # si on utilise deux affectations différentes
    a = []
    b = []

# alors on peut changer a sans changer b
    a.append(1)
    print('a', a, 'b', b)
a [1] b []
```

On voit que dans ce cas chaque affectation crée une liste vide différente, et les deux variables ne partagent plus de donnée.

D'une manière générale, utiliser l'affectation simultanée vers un objet mutable crée mécaniquement des **références partagées**, aussi vérifiez bien dans ce cas que c'est votre intention.

3.24 Les instructions += et autres revisitées

3.24.1 Complément - niveau intermédiaire

Nous avons vu en première semaine (Séquence "Les types numériques") une première introduction à l'instruction += et ses dérivées comme *=, **=, etc.

Ces constructions ont une définition à géométrie variable

En C quand on utilise += (ou encore ++) on modifie la mémoire en place - historiquement, cet opérateur permettait au programmeur d'aider à l'optimisation du code pour utiliser les instructions assembleur idoines.

Ces constructions en Python s'inspirent clairement de C, aussi dans l'esprit ces constructions devraient fonctionner en **modifiant** l'objet référencé par la variable.

Mais les types numériques en Python ne sont **pas mutables**, alors que les listes le sont. Du coup le comportement de += est **différent** selon qu'on l'utilise sur un nombre ou sur une liste, ou plus généralement selon qu'on l'invoque sur un type mutable ou non. Voyons cela sur des exemples très simples :

```
In [1]: # Premier exemple avec un entier
        # on commence avec une référence partagée
        a = b = 3
        a is b
Out[1]: True
In [2]: # on utilise += sur une des deux variables
        a += 1
        # ceci n'a pas modifié b
        # c'est normal, l'entier n'est pas mutable
        print(a)
        print(b)
        print(a is b)
4
3
False
In [3]: # Deuxième exemple, cette fois avec une liste
        # la même référence partagée
        a = b = []
        a is b
Out[3]: True
```

Vous voyez donc que la sémantique de += (c'est bien entendu le cas pour toutes les autres formes d'instructions qui combinent l'affectation avec un opérateur) **est différente** suivant que l'objet référencé par le terme de gauche est **mutable** ou **immuable**.

Pour cette raison, c'est là une opinion personnelle, cette famille d'instructions n'est pas le trait le plus réussi dans le langage, et je ne recommande pas de l'utiliser.

Précision sur la définition de +=

Nous avions dit en première semaine, et en première approximation, que :

```
x += y
était équivalent à :
x = x + y
```

Au vu de ce qui précède, on voit que ce n'est pas tout à fait exact, puisque :

```
In [5]: # si on fait x += y sur une liste
    # on fait un effet de bord sur la liste
    # comme on vient de le voir

a = []
    print("avant", id(a))
    a += [1]
    print("après", id(a))

avant 82877176

In [6]: # alors que si on fait x = x + y sur une liste
    # on crée un nouvel objet liste

a = []
    print("avant", id(a))
    a = a + [1]
    print("après", id(a))
```

avant 82981752 après 82877496

Vous voyez donc que vis-à-vis des références partagées, ces deux façons de faire mènent à un résultat différent.

3.25 Classe

3.25.1 Exercice - niveau basique

On veut implémenter une classe pour manipuler une queue d'événements. La logique de cette classe est que :

- on la crée sans argument;
- on peut toujours ajouter un élément avec la méthode incoming;
- et tant que la queue contient des éléments on peut appeler la méthode outgoing, qui retourne et enlève un élément dans la queue.

Cette classe s'appelle Fifo pour *First In, First Out,* c'est-à-dire que les éléments retournés par outgoing le sont dans le même ordre où ils ont été ajoutés.

La méthode outgoing retourne None lorsqu'on l'appelle sur une pile vide.